Role Benchmark：交互式科学参数辨识与规律归纳的配对评测协议

技术报告，版本 0.8.0

2026-09-03

版本快照。本报告描述 2026 年 9 月 3 日冻结的仓库版本 0.8.0。2026 年 8 月 30 日的 corpus audit 仍是 29 个已接纳公开 family 和 116 个原始 development instance 的证据。版本 0.8.0 新增三种 evaluation methods、统一最终 predictor 表示、连续主指标、显式 condition semantics、Temporal exposure record，以及已登记的 easy/hard H/C variants。`EXP-METHOD-PILOT-001` 已冻结但尚未运行。

摘要

Role Benchmark 是一个用于评测语言模型智能体交互式科学建模能力的 Python 框架。它区分两种 task settings：在**参数辨识**设置中，响应函数族和参数槽位向智能体公开；在**规律归纳**设置中，真值特有函数族被隐藏。两种设置均用共同的表达式语言提交同一种可执行 predictor。20 个 curated families 将遵循熟悉科学关系的历史条件与最小改变的反事实条件配对；9 个独立 Temporal families 各含两个 source-reported conditions，不进入 H/C 配对 estimands。

冻结比较包含三种 evaluation methods：prior-only baseline、fixed experimental design 和 adaptive experimental design。Fixed 与 adaptive methods 使用相同的 family-specific observation budget。主要 Oracle 是确定性实现；可选 LLM presentation 只能返回与确定性结果完全一致的结构化 observation，在完成准确性评价前不进入主要配置。主要结果为 held-out condition-readout pairs 上的 `1 / (1 + mean scaled absolute error)`。Binary pass、protocol completion、trajectory diagnostics 和 post-hoc LLM evaluation 均为次要结果，不能覆盖确定性分数。

当前公开开发集包含 80 个原始 H/C instances 和 36 个 source-reported Temporal instances。Easy/hard variants 均为完整 H/C pairs：curated easy 使用原 C 关系，hard 使用 H/C 中点；另有一个独立 authored pack 为四个具有连续机制坐标的 Temporal-derived families 生成 H/C variants，但不重标或修改原 Temporal conditions。仓库目前没有私有测试集。因此，公开模型运行只能作为开发证据，不能解释为抗污染排行榜结果。

术语约定

原文术语	本报告统一译法	操作性含义
identification	参数辨识	已知正确响应 family，估计其参数
discovery	规律归纳	未公开真值特有 family，提交通用预测器
family	科学 family	一组共享装置和变量定义的 benchmark instances
historical condition	历史条件	符合熟悉科学关系的现代化理想条件
counterfactual condition	反事实条件	只改变一个机制坐标的 benchmark 条件
task setting	任务设置	参数辨识或规律归纳的公开信息条件
Player	Player	接受测评的模型或智能体 profile
Oracle	Oracle	校验实验并返回证据的可信接口
WorldModel	WorldModel	benchmark 端私有的确定性真值响应函数
confidence	报告支持权重	不等同于已校准的贝叶斯后验概率
held-out	接口内隐藏	在公开 fixture 中不构成开发者级安全隔离

1. 研究动机

当智能体返回一个经典公式时，它可能真正从证据中归纳了规律，也可能从训练数据中回忆了公式，或只是在已公开模板中填入参数。当智能体在改变后的条件中失败时，它可能受熟悉科学先验锚定，也可能只是实验选择不当、系数估计错误、表达式构造失败或违反协议。单一成功率无法区分这些解释。

已有 benchmark 已经覆盖交互式实验、改变的物理规律、受控先验信息、符号方程恢复和完整科研循环 (Jansen et al. 2024; Y. Chen et al. 2025; Zheng et al. 2026; Wiemann et al. 2026; Wang et al. 2026)。Role Benchmark 处理的是更窄的测量缺口：通过 matched comparison 分别操纵先验一致性和 family disclosure。项目拟主张的贡献是这一 factorial diagnostic 及其可审计执行合同，而不是“首个科学发现 benchmark”。

本报告的核心论点是：

一项有效的科学智能体 benchmark，应分别记录智能体在实验前获得了什么信息、选择了什么证据、显式假设如何响应证据，以及最终预测器能否泛化。

2. 目标、非目标与证据边界

2.1 目标

当前实现旨在：

1. 比较公开函数族的参数辨识和函数族未公开的预测规律归纳；
2. 比较与既有科学先验一致的历史条件和最小改变的反事实条件；
3. 只向 Player 暴露可序列化的公开状态；
4. 强制提交各假设的事前数值预测；
5. 通过隐藏干预上的确定性预测评分最终模型；
6. 保存完整、canonical 且可 replay 的可观察轨迹；
7. 分别诊断协议、实验选择、证据更新和最终建模失败；
8. 支持可审计的、由近期论文构造的 temporal evaluation instance。

2.2 非目标

本项目不声称评测无约束的科学发现、私有思维链、经校准的贝叶斯信念、最优实验设计、真实实验室安全或自主发表能力。固定实验预算只是比较条件，不是贡献。Historical case 是受已有科学关系启发的现代化理想条件，并非历史实验的档案重建。Counterfactual condition 是人为编写的 benchmark mechanism，不是关于自然界的科学主张。

2.3 当前证据状态

项目拥有较强的实现一致性证据，但 benchmark validity 证据尚不完整。现有 audit 验证了已接纳真值、Oracle response 和 evaluator 之间的一致性，却不能建立跨科学领域的外部效度、抗污染能力、人类与模型的可比性，或 family disclosure 的因果效应。支持这些更强主张需要 private evaluation pack、预注册的重复运行，以及对定性指标的人工校准。统一最终 predictor representation 消除了一个已识别的测量混淆，但本身不能建立因果效应。

3. Benchmark 形式化

3.1 Case family

一个 family f 可概括为：

$$\mathcal{C}_f = (\mathcal{X}_f, \mathcal{Y}_f, \mathcal{A}_f, B_f, g_{f,H}, g_{f,C}, \mathcal{Q}_f^{\text{diag}}, \mathcal{Q}_f^{\text{test}}).$$

其中，$\mathcal{X}_f$ 是合法控制域，$\mathcal{Y}_f$ 是带类型的 readout 空间，$\mathcal{A}_f$ 是装置与资源合同，B_f 是实验预算。私有响应函数 $g_{f,H}$ 和 $g_{f,C}$ 分别定义 Historical 与 Counterfactual conditions。Diagnostic conditions 用于在 case 构造阶段确认两个条件可由合法干预区分；test conditions 用于评价最终预测器，不会通过正常 Player API 返回。

3.2 两种任务设置

两种任务设置的区别在于公开信息合同。

属性	参数辨识	规律归纳
Family 信息	完整的 case-specific family scaffold	隐藏真值特有 family
未知对象	具名有限参数	可执行响应函数
最终提交	共同的 `expression` program	共同的 `expression` program
主要判据	隐藏干预上的预测	同类预测判据
目标构念	主动固定 family 参数估计	主动预测规律归纳

规律归纳不是无表示约束的任务。通用表达式 grammar、控制量、readout 和评测域都是公开 inductive bias。如果向 Player 提供有限的真值特有候选列表，该任务应被称为受约束模型选择，而不是本协议中的 discovery task setting。

3.3 Matched 2×2 设计

每个已接纳 family 产生四个公开开发 cell：

	参数辨识	规律归纳
Historical condition	H, I	H, D
Counterfactual condition	C, I	C, D

设计要求以下 invariant：

- 两个条件使用相同的公开装置、控制量、readout、范围、单位、预算和定性背景；
- 同一条件中的两种任务设置共享 WorldModel 和 evaluator conditions；
- 反事实只改变一个预先声明的机制坐标；
- 预算内存在能够区分两个条件的合法干预；
- 任一条件的已知真值至少会在配对条件的一个隐藏测试上失败。

令 Y 为连续 held-out prediction score。对每种 task setting，登记的 H/C estimands 为：

$$\Delta_0 = \mathbb{E}_f[Y_{f,H,0} - Y_{f,C,0}],$$

$$\Delta_F = \mathbb{E}_f[(Y_{f,C,F} - Y_{f,C,0}) - (Y_{f,H,F} - Y_{f,H,0})],$$

以及

$$\Delta_A = \mathbb{E}_f[(Y_{f,C,A} - Y_{f,C,F}) - (Y_{f,H,A} - Y_{f,H,F})].$$

其中 $0, F, A$ 分别表示 prior-only、fixed 和 adaptive experimental design。Temporal rows 在各自 source-reported condition 内独立分析，绝不进入这些 H/C estimands。

4. 系统架构

该 package 是位于 `src/role_benchmark/` 下、仅依赖 Python 3.9+ 标准库的实现。架构明确分离公开数据、可信真值、交互状态、评分和持久化。

4.1 组件

组件	职责	主要实现
Public model	不可变、可序列化的 case/action/evidence/result 类型	`models.py`
Player wire protocol	严格版本化 JSON decoding 与 canonical encoding	`wire.py`
Episode state machine	预算、portfolio、停止和终止语义	`episode.py`
Oracle interface	资源校验与证据返回	`protocols.py`
WorldModel	私有确定性响应函数	各 case module
Expression runtime	使用所有 task families 共用 grammar 的经验证 predictor AST	`expression.py`
LLM adapter	provider-neutral generation request/response 边界	`llm.py`
Run logging	Append-only canonical JSONL event 与 replay	`runlog.py`
Trajectory scoring	预测分离与证据一致移动	`trajectory.py`
Failure analysis	可观察、分阶段的失败 taxonomy	`failure_modes.py`
Optional judge	严格 decoding 的事后定性评价	`llm_evaluator.py`
Temporal authoring	获取、抽取、复核、过滤和渲染	`temporal/`

4.2 信任边界

可信 benchmark 端持有 `BenchmarkCase`，其中包含公开 `CaseDefinition`、私有 `WorldModel` 和私有 final evaluator。Player 只接收 `EpisodeView`，其中包括公开 case、已使用和剩余 attempt 数，以及可观察 turn history。Evaluator 只在 final submission 后运行，不是参与交互的第三个角色。

进程内 Python 对象分离只是一种 API discipline，不构成 security boundary。由于公开源码包含真值和 scorer，正式部署必须把 Player 放在独立执行环境中，并且只暴露序列化请求与响应。

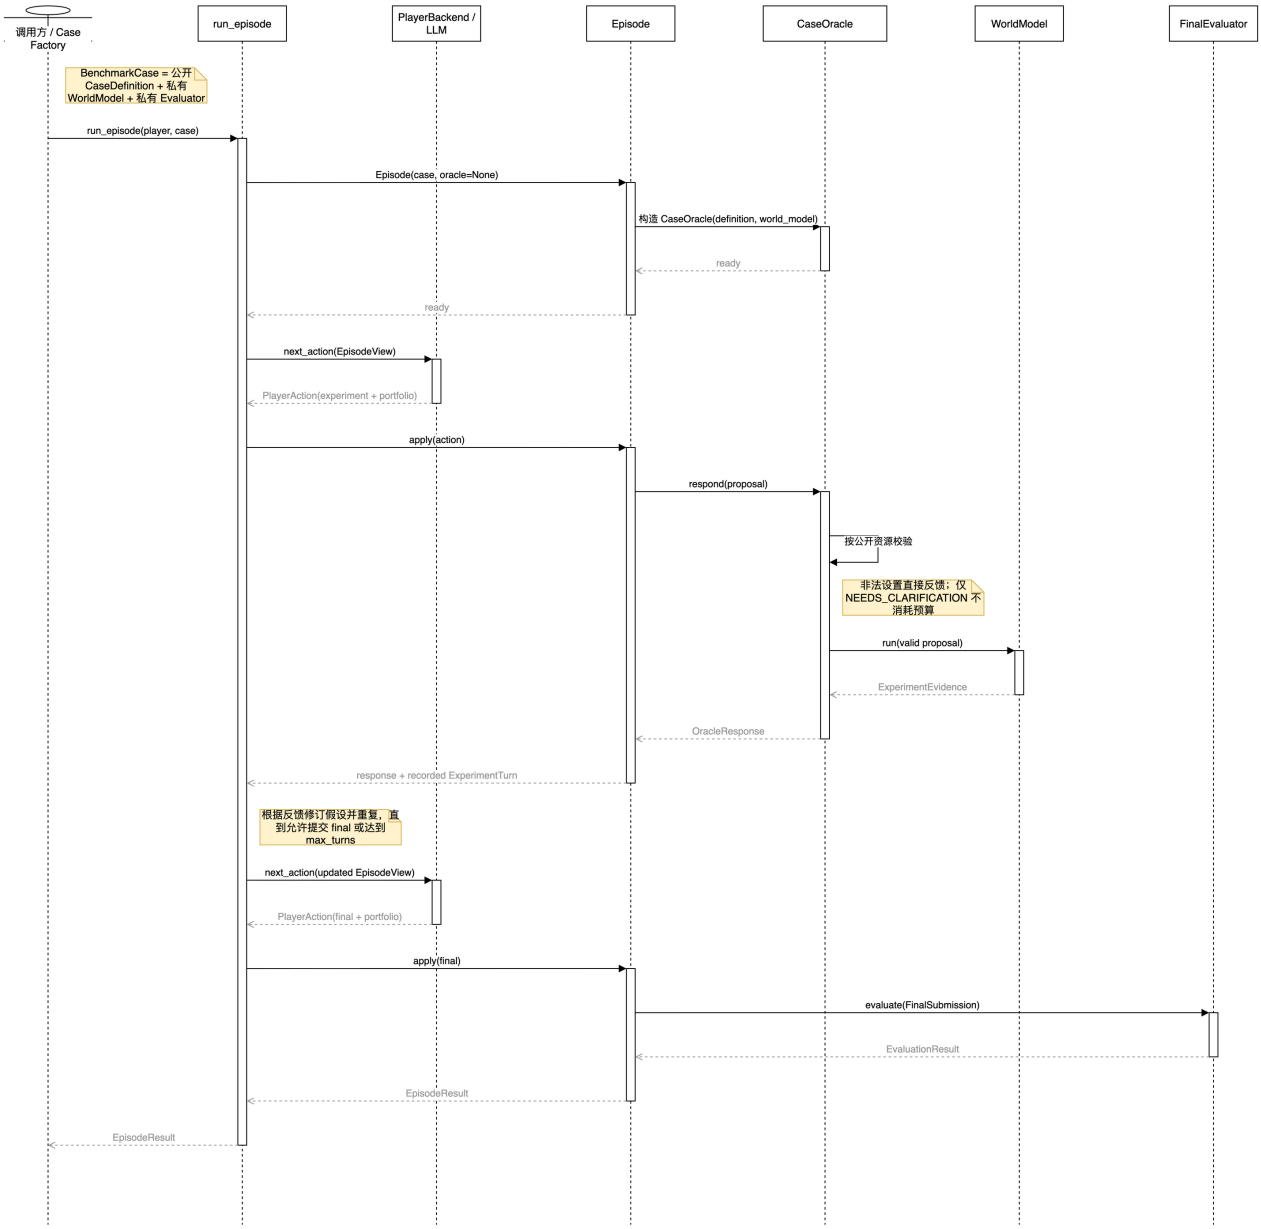


Figure 1: Role Benchmark 架构

4.3 执行序列

一次 episode 按以下顺序运行：

1. 实例化 case，并冻结其公开定义快照；
2. 将 `EpisodeView` 序列化为版本化 prompt；
3. 请求 Player backend 生成一个 action；
4. 严格 decode action，不进行科学内容修复；
5. 若 action 为实验，则校验 portfolio 和资源请求；
6. 若实验有效，则执行 WorldModel 并返回 typed evidence；
7. 将 action、Oracle response 和 metadata 追加到 run log；
8. 重复上述过程，直到出现有效 final action 或 Player-side terminal failure；
9. 对已提交模型运行确定性 case evaluator；
10. 计算 trajectory score 和 failure diagnostic；
11. 持久化 terminal outcome，以便 replay 与 aggregation。

`NEEDS_CLARIFICATION` 不消耗实验预算；`VALID`、`UNAVAILABLE_INSTRUMENT`、`OUT_OF_RANGE` 和 `INVALID_SETUP` 均消耗一次预算。独立的最大 action 限制用于防止不良 Player 无限提出 clarification request。

5. 公开数据与动作协议

5.1 公开 case definition

`CaseDefinition` 包含 case identifier、标题、背景、初始观察、resource catalog、预算、支持权重阈值、任务设置和最大假设数。Resource catalog 声明 instrument、control、合法范围或枚举值、readout、单位、resolution、statistic 和 uncertainty semantics。这些声明使系统能在执行私有真值之前完成确定性验证。

5.2 假设 portfolio

对于实验 action，Player 必须提供至少两个具体假设。假设 ID 必须唯一且不能使用保留名，有限支持权重之和必须归一化为一。协议禁止 `OTHER`，因为一个没有被明确陈述的剩余类别不能产生可检验预测。Portfolio 可以在 turn 之间增加、删除或改写假设；但如果复用同一 ID 表示已经改变的 statement，该 pair 会被排除在 belief-update scoring 之外。

解释 `confidence` 时，框架采用“报告支持权重”这一术语。假设不要求互斥或完备，系统也没有校准检验将其转化为贝叶斯后验。

5.3 实验 proposal

`ExperimentProposal` 包含 intent、apparatus、完整 control、所请求 readout、replicate 数和 forecast。对于每个活动假设及每个数值 readout，forecast 必须在 Oracle 生成证据前存在且为有限数值。这一 invariant 使以下比较可由机器审计：

- 所选 setup 是否能区分 Player 当前假设；
- 哪个假设对证据的预测更接近；
- 下一次报告支持状态朝向还是背离了预测更好的假设。

Oracle 返回 `VALID`、`NEEDS_CLARIFICATION`、`UNAVAILABLE_INSTRUMENT`、`OUT_OF_RANGE` 或 `INVALID_SETUP` 之一。只有 `VALID` response 携带 `ExperimentEvidence`。

5.4 最终提交与停止

`FinalSubmission` 包含 explanation、model identifier、parameters、可选的 selected hypothesis ID 和 scope conditions。在预算耗尽前，只有当被选假设达到 case threshold 时才允许主动提交。预算耗尽后，无论支持权重多低都允许提交。达到 threshold 只表示允许停止，不表示科学正确。

只要最终科学模型能够被严格 decode，即使关联 portfolio 或停止 metadata 违反过程合同，模型仍会被评价，违规另行附加。如果不存在可 decode 的最终主张，则不调用 evaluator，并记录 `player_output_invalid`、`action_rejected` 或 `action_limit` 等 Player-side termination。

5.5 严格 wire format

Wire layer 校验 plain JSON tree、有限数值、UTF-8 文本、depth 和 node limits、key、schema version 以及 action shape。Canonical serialization 在项目内部是确定性的，但不声称符合跨语言 RFC 8785。Schema-directed regeneration 默认关闭。如果显式启用，它就是可能改变科学内容的第二次模型生成，必须作为不同 evaluation profile 单独报告。

6. Oracle 与 WorldModel 设计

6.1 确定性 Oracle

`CaseOracle` 首先根据公开 resource catalog 检查 proposal。无效请求只返回中性 status，不携带真值证据。有效 proposal 传给 case WorldModel，由后者依据私有条件定义返回 measurement、unit 和 uncertainty。

确定性具有三个作用：精确 replay、客观 regression test 和清晰比较 Player policy。这里的“正确”仅表示与已声明 case data-generating process 一致，并不表示对自然界普遍正确。

6.2 表达层

可选的 LLM Oracle presentation layer 可以把确定性 evidence 改写成自然语言，但不能生成 measurement。因此，只要请求上下文和权限分离，即使 Player 与 presenter 使用相同 provider 或 model ID，也不会使两个角色合并。

6.3 Oracle 模式与适用范围

版本 0.8.0 提供两种 Oracle 模式。主要的 `deterministic` 模式在验证请求后直接返回 WorldModel observation，不调用 Oracle LLM。可选的 `llm_presentation` 模式使用单独配置的 Oracle interface 表达该 observation，但只在其结构化 observation 与确定性结果完全一致时接受输出。因此，第二种模式测量的是表达效应，不是独立抽样的测量过程。其事实可靠性尚未经实验确立，也不在已冻结的 method pilot 中使用。

7. 可执行模型表示

Identification 与 discovery case 都使用共享的 `expression` model。提交的 predictor 是由公开 input variable、允许 constant 和受限 operator 组成的 validated expression tree。Evaluator 执行前，validator 会拒绝 malformed structure、非有限值、禁止变量和不支持操作。Identification 额外公开 model specification、formula、parameter meaning 和 domain；discovery 隐藏这些信息。两者其余 parser、evaluator、held-out condition 和 score 完全相同。该设计排除了输出表示对 task-setting contrast 的混杂，同时避免执行任意 Player Python。

8. 评分模型

8.1 主要科学结果

Case evaluator 在预注册干预上执行结构化 predictor。对第 i 个 held-out condition–readout pair，定义

$$e_i = \frac{|\hat{y}_i - y_i|}{\tau_{\mathrm{abs},i} + \tau_{\mathrm{rel}}|y_i|}.$$

主要结果为

$$\texttt{held_out_prediction_score} = \frac{1}{1 + \frac{1}{n}\sum_{i=1}^{n} e_i}.$$

对于有效的有限数值提交，该分数位于 $(0, 1]$，误差越小分数越高；每个 condition–readout pair 等权。Player 未提交或提交无效时记为 0；infrastructure failure 记为缺失，报告后在同一 schedule position 重跑。

二元次要结果为：

`scores["predictive_model_pass"]`

当所有 scaled error 均不超过一时为一，否则为零。该指标不评价 prose explanation，不要求恢复 benchmark reference expression 的相同代数形式，也不证明声明域外的全局等价。

报告应分别给出 `protocol_completion`、`submission_available`、连续主指标、全部已评价 episode 上的 binary pass 和 infrastructure failure。只在已提交 episode 上计算正确率，会通过丢弃协议失败而夸大脆弱智能体的科学能力。

8.2 轨迹诊断

系统从可观察记录计算两个 headline diagnostic：

- `experiment_discriminativeness_mean`：有效实验中，各假设事前预测的平均成对相对分离度；
- `evidence_aligned_belief_update_rate`：对持续存在的假设 pair 求平均。支持权重朝 lower-error hypothesis 移动记为 1，不变记为 0.5，反向移动记为 0。

配套 count 包括 forecast pair、可评分 update pair、aligned/inert/opposed update、非区分证据后的 unsupported shift、hypothesis rewrite 和 duplicate setup。Pair count 为零表示“该 episode 中不可测”，而不是更新质量差或完美。

这些 metric 有意保持局部性。第一个指标不比较实际实验与所有可选合法实验，也不是 expected information gain。第二个指标不是 Bayesian calibration。它们不应与 predictive pass 合成为一个不透明总分。

8.3 可选事后 evaluator

可选 LLM evaluator 接收已结束的可观察 transcript，严格输出 experimental design、evidence use、hypothesis revision、stopping、claim–evidence consistency 和 explanation quality 等轴。它不读取 hidden chain-of-thought，也不能改变确定性正确性。若要升级为正式 metric，需要 expert-labelled calibration set、multiple-judge reliability analysis 和偏差测试 (Zheng et al. 2023)。

8.4 失败定位

`failure_modes.py` 只用 observable event 将 mismatch 定位到 generation、protocol、experiment choice、forecast、update、commitment 或 held-out generalization 阶段。每条 diagnosis 都记录稳定 code、stage、evidence turn 和 event reference。语言保持行为层次：analyser 可以报告“支持权重背离 lower-error forecast”，但不能推断“模型固执”等隐藏心理原因。

9. Case corpus

9.1 Built-in family

20 个由研究者构造的任务族覆盖力学、光学、电学、热力学、动力学、输运和随机过程中的理想化关系：

- `pendulum`
- `young_double_slit`
- `galileo_inclined_plane`
- `boyle_j_tube`
- `photoelectric`
- `faraday_induction`
- `radioactive_decay`
- `rutherford_scattering`
- `hooke_spring`
- `torricelli_efflux`
- `ohm_circuit`
- `rc_discharge`
- `stefan_boltzmann`
- `newton_cooling`
- `beer_lambert`
- `michaelis_menten`
- `coulomb_force`
- `kepler_orbit`
- `brownian_diffusion`
- `poiseuille_flow`

每个 task family module 都构造两个数据生成条件和两个任务设置。共享验证程序校验公开接口等价、单机制坐标变化，并确认每个条件的真实预测器不能通过配对条件的隐藏测试。

9.2 Temporal family

9 个独立注册的 temporal family 以近期论文为来源：

- `kz_incompressible_energy_temperature_regimes`
- `viscous_inertial_rheology`
- `rilw_msd_scaling`
- `defect_sre`
- `trxas_lorentzian_fit`
- `self_similar_spreading_radius_ratio`
- `stealthy_hyperuniform_localization_scaling`
- `uamo_lyapunov`
- `statistical_mean_field_effective_detuning`

`lyapunov_scaling` 与 `quantum_control_threshold` 两个 candidate 仍被拒绝，因为拟议的 paired conditions 不能在共同 observable contract 下表示互斥机制。这是一个重要科学 gate：两个数值上正确的公式并不会自动组成有效 matched family。

9.3 Inventory 语义

原始 inventory 包含 $20 \times 2 \times 2 = 80$ 个 H/C development instances 和 $9 \times 2 \times 2 = 36$ 个 Temporal development instances；后者的两个 conditions 是 source-reported roles，而不是 H/C roles。所有 truth 和 evaluator 均随源码发布。因此，这里的 held-out 只表示正常 episode 中不通过 Player interface 提供，并不意味着阅读仓库的开发者无法获得。

10. Temporal paper-to-case pipeline

Temporal subsystem 把近期 source material 编译成经过复核的 case module。其设计将概率性 proposal generation 与确定性 admission 分开。

10.1 Acquisition

对冻结的 inclusive date window 和固定 journal ISSN，acquisition stage：

1. 穷尽 Crossref record，而不是在得到方便数量后提前停止；
2. 要求 DOI-keyed publisher reconciliation，提供 category、original-research status、publication date 和 withdrawal/retraction status；
3. 根据 DOI 及严格 title/first-author evidence 召回 arXiv candidate；
4. 优先接受唯一 DOI match；只有 candidate 没有声明冲突 DOI 时，才接受唯一 exact-title/first-author match；
5. 冻结 versioned arXiv source bundle；
6. 要求 source bundle 中至少存在一个 TeX 文件。

Pipeline 是可重跑的固定窗口快照，不是持续监听服务。它采取 precision-first 策略：身份模糊、缺少 TeX 或 reconciliation 不完整都会终止自动路径。

10.2 ScienceCard 抽取与复核

第一个 LLM 接收冻结并带行号的 source packet，抽取结构化 ScienceCard，其中包含 mechanism、control、readout、fixed condition、uncertainty、applicability 和 claim dependency。每一项科学信息都必须携带 source locator。只有 allowlisted schema 或 locator failure 可以触发有界的 mechanical regeneration。

随后由独立 reviewer 检查 source fidelity。被判定需要修订的 card 不能授权 drafting，必须在新 output directory 中针对同一 frozen source 修订。该规则防止 extractor 自行批准自己的结论。

10.3 Matched draft 与 binding

第二个 LLM 只读取通过复核的 ScienceCard，不读取完整论文，也不能使用外部记忆补充科学事实。它可以提出零个或一个 matched family scaffold。确定性代码把 immutable source ID、control、readout、fixed condition 和 locator 绑定到 runtime-safe name。模型不能在 reviewed card 之外发明公开科学事实或可执行真值。

10.4 Filter、family review 与 render

Hard filter 检查 lineage、information leakage、observation capacity、identifiability、legal domain、condition matching 和 discovery non-degeneracy。第二个独立 family review 评价两个 mechanism 是否构成科学上有意义的 matched pair。只有通过全部 gate 后，deterministic renderer 才生成 Python module 和 four-cell canary validation。已接纳 temporal module 使用与冻结 built-in set 分开的 registry。

10.5 Provenance 与 resumability

每个 stage 保留 exact request、raw response、parsed artifact、review、filter result 和不含 credential 的 config。Coordinator 冻结 acquisition input 与 source packet，为 awaiting review、provider failure、revision、exhaustion 和 acceptance 使用显式 exit code，并在 resume 时重新验证已经消费的 artifact。这一流程得到的是可审计 authoring process，而不是 “LLM 生成 case 自动正确” 的证明。

11. Logging、replay 与可复现性

Run log 是 append-only JSONL event stream，并采用 canonical serialization。它记录 prompt、raw generation、parsed action、transition、evidence、token usage、repair call、termination、evaluation 和 trajectory score。Replay 可以把 parser behavior 检查与在调用方 runtime 上的行为重执行分开。

Canonical aggregation grain 是每个 episode 一个持久化 result sidecar。Resume log 代表 attempt，而不是额外 episode。这一区分避免中断运行重复增加统计分母。

完整 evaluation profile 应冻结：

- repository commit 和 package version；
- case pack 与 case assignment；
- scorer version 和 hidden-test pack；
- model/provider identifier 及实际返回的 model metadata；
- system prompt、action schema 和 tool permission；
- temperature 与 generation limit；
- repair policy；
- Oracle mode；
- repeat count 和 schedule；
- infrastructure-failure disposition。

12. 验证与质量保证

2026 年 8 月 31 日的 objectivity re-audit 与 9 月 3 日的 P0.1–P0.6 regression run 报告：

检查	结果
已接纳 family	29 / 29 已注册
公开 matched cell	116
已知真值被接受	116 / 116
来自配对条件的错误预测器被拒绝	116 / 116
合法 Oracle 查询为有限值且单位一致	1,242 / 1,242
重复确定性 response 完全一致	1,242 / 1,242
当前单元测试与集成测试	446 passed / 0 failed

测试覆盖 model、case factory、historical/temporal contract、expression validation、wire encoding、episode semantics、LLM adapter、run log、failure mode、experiment matrix、temporal acquisition、ScienceCard extraction、authoring、filter、cohort selection 和 warm-up coordination。

这些检查建立内部一致性。Source fidelity 另行根据各 case credit 或 temporal source packet 复核，项目没有把 executable self-consistency 当成科学正确性的充分证明。

13. 公开开发运行状态

`out/bench_results_summary_20260830/summary.json` 中的存档摘要描述一个计划包含 1,600 个 episode 的四模型析因实验，即 20 个任务族 × 4 个实验条件 × 5 次重复 × 4 个模型。截至该快照，820 个 episode 有可评价结果，其中 457 个在 adaptive experimental design 条件下无条件通过。只有 GPT-5.6 Sol 完成了 400/400 episode；Claude Opus 4.7 有 350 个可评价 episode，Kimi K3 和 Qwen 3.5 各有 35 个。

这些结果不能用于模型横向排名。不同模型 coverage 严重不平衡，三个模型运行未完成，case 全部公开，报告也没有 formal private assignment。该 artifact 适合验证 aggregation 并区分协议失败与科学失败。论文应完成预注册矩阵，或明确把 partial result 标记为 engineering diagnostic。

14. 与已有工作的关系

Role Benchmark 位于丰富科学环境与静态方程恢复之间。DiscoveryWorld 和 ScienceWorld 强调 grounded action (Jansen et al. 2024; Wang et al. 2022)。Auto-Discovery-Bench 和 FALSIFYBENCH 提供受控的 Oracle-guided rule diagnostic (T. Chen et al. 2025; Bertolazzi et al. 2026)。Gravity-Bench、PhysGym、NewtonBench 和 DiscoverPhysics 已经建立主动反事实物理与可执行规律发现 (Koblischke et al. 2025; Y. Chen et al. 2025; Zheng et al. 2026; Wiemann et al. 2026)。符号回归研究独立于语言模型智能体建立了方程恢复传统 (Schmidt and Lipson 2009; Brunton et al. 2016; Udrescu and Tegmark 2020)。论文衍生 benchmark 则建立了近期来源任务构造与可执行研究评测 (Z. Chen et al. 2025; Kon et al. 2026; Starace et al. 2025; Wang et al. 2026)。

项目在 matched task family 内使用 factorial design，分别比较 prior alignment 和 model-class disclosure；要求 pre-experiment predictions，并将 deterministic held-out prediction 与 process-evaluation measures 分开报告。完整中文文献综合和比较矩阵见 `paper_drafts/related_work_comprehensive_zh.md`。

15. 效度威胁

15.1 构念效度

- 隐藏条件上的预测成功比科学发现窄得多。
- Discovery 使用受限 expression language 和已知 control/readout interface。
- Identification 公开 model specification 而 Discovery 不公开；这一预先规定的信息操纵仍可能改变 prompt length 和 reasoning strategy。
- 报告支持权重不是 calibrated belief。
- Forecast separation 不能证明实验在全局意义上信息充分。
- 少量确定性隐藏干预不能证明所有条件上的代数等价。

15.2 内部效度

- 公开源码暴露 truth、assignment 和 evaluator。
- In-process privacy 不构成 adversarial isolation。
- Provider behavior、prompt scaffold 和 repair policy 可以独立于 model weight 改变结果。
- 未完成运行和 coverage 不平衡使朴素模型比较无效。
- Historical 与 Counterfactual conditions 的公开表述必须足够匹配，避免 identifier 或 wording 泄露 condition assignment。

15.3 外部效度

- 大多数 case 是确定性、低维的理想世界。
- 20 个由研究者构造的任务族主要来自经典定量关系；9 个由近期论文构造的 temporal task family 扩大了来源，却不足以建立领域代表性。
- 真实科学包含噪声、latent variable、装置失败、变化目标和文献依赖，本项目尚未覆盖。
- Benchmark 成功不意味着具备安全或实用的真实实验室自主能力。

15.4 Temporal 与 source validity

- Acquisition funnel 选择能高精度对齐 journal–arXiv 且具有 TeX 的论文，因此存在可测量 selection effect。
- 近期发表只能降低部分记忆风险，不能保证没有暴露。
- Source reviewer 验证 frozen packet 中的支持关系，并未独立重复论文实验。
- 日期化文档记录不同开发阶段。Snapshot claim 必须引用当前 registry 和 audit artifact。

16. 正式评测要求

一个可辩护的 formal release 应满足：

1. 私有 family assignment、truth 和 test intervention 位于可信服务端；
2. Player 在独立 sandbox 中运行，并声明 network、retrieval 和 filesystem access；
3. Case ID 和公开 prose 对 condition 与 source assignment 保持中性；
4. 两种 task settings 使用共同的可执行 predictor representation；
5. 预注册 model profile、prompt、budget、schedule、repeat 和 aggregation；
6. 将 infrastructure failure 与 Player failure 分开；
7. confidence interval 以 family 和 repeated cell 为 cluster；
8. 四个 cell 获得相同 planned coverage；
9. 定性 judge 根据 expert label 校准，并且永不替代 executable correctness；
10. Release report 明确区分 public development、sealed validation 和 final test pack。

17. 建议实验计划

下一阶段应优先提高效度，而不是继续增加更多公开 family。

Phase A: Development method pilot

按冻结的 `EXP-METHOD-PILOT-001` 配置运行，不改变 families、methods、repeats、primary outcome 或 deterministic Oracle。缺失不可变 API snapshot 和 training-data cutoff 必须作为明确限制报告，不能解释为未接触来源材料的证据。

Phase B: Private matched pack

构造 held-out validation set 与 final test set，其中包含新的基于公认科学关系的任务族，以及由近期论文构造的 temporal task family。被评测模型在可信服务之外运行，系统只记录序列化通信。

Phase C: 预注册 factorial evaluation

不同模型使用相同 schedule，并设置足够 repeat 估计 family-level uncertainty。报告连续 held-out prediction score、Δ_0、Δ_F 和 Δ_A，并给出 family-clustered uncertainty。Binary pass、protocol completion、有效提交条件下的结果和 trajectory coverage 均为次要结果。

Phase D: Mechanism check

移除 canonical name、historical cue 或 source-era information，检查性能是否变化。比较 final-only prompt 与显式 hypothesis/forecast protocol，测量轨迹合同是否提供额外诊断价值。

Phase E: Oracle ablation

Case truth 冻结后，实现真正独立的 probabilistic Oracle，并在相同公开接口下比较事实准确性、方差、Player outcome 和 failure mode。

18. 安装与运行

Package 除 Python 标准库外没有 runtime dependency。

```
python3 -m pip install -e .
PYTHONPATH=src python3 -m unittest discover -s tests -v
```

可以直接实例化并查询一个确定性 case:

```
from role_benchmark.cases import make_pendulum_case
from role_benchmark.models import ExperimentProposal
from role_benchmark.protocols import CaseOracle

case = make_pendulum_case("historical")
oracle = CaseOracle(case.definition, case.world_model)
response = oracle.respond(
    ExperimentProposal(
        intent="Vary length while holding other controls fixed.",
        apparatus="simple_pendulum",
        controls={
            "length_m": 1.0,
            "bob_mass_kg": 0.2,
            "release_angle_deg": 5.0,
        },
        readouts=("period_s",),
        replicates=5,
    )
)
print(response.status.value, response.evidence.measurements)
```

在正式 benchmark episode 中，LLM backend 负责生成完整 `PlayerAction`，包括 portfolio 和 forecast。直接调用 Oracle 主要用于开发与 case validation。

19. 结论

Role Benchmark 实现了一套结构连贯且高度可审计的交互式科学建模诊断。它最突出的特征不是交互、反事实物理或方程恢复中的某一项单独创新，而是把 Historical/Counterfactual conditions 与 Identification/Discovery information contracts 进行受控组合。严格公开类型、确定性证据、可执行隐藏评分、事前 forecast 和 canonical replay 共同使失败可定位。

当前实现已经足以支持冻结的 development method pilot：29 个 family、116 个原始 development instances、统一最终 predictor contract、三种 evaluation methods、显式 condition roles 和版本化连续分数均已实现。科学结论仍必须保持克制。由于没有 private pack，且登记的 API alias 没有不可变 snapshot 或有证据支持的 cutoff，版本 0.8.0 是公开开发工具，

而不是通用科学发现能力或 post-checkpoint performance 的最终 benchmark。下一步是在扩大模型或 case 数量前执行冻结 pilot。

附录 A：仓库结构

路径	内容
`src/role_benchmark/`	核心协议、LLM adapter、scoring 和 replay
`src/role_benchmark/cases/`	20 个 built-in matched family
`src/role_benchmark/temporal/`	Paper-to-case acquisition 和 authoring pipeline
`src/role_benchmark/temporal_cases/`	9 个已接纳 temporal family
`tests/`	单元测试与集成测试
`experiments/`	Matrix runner、analysis 和 temporal authoring tool
`examples/`	最小用例、replay 和 failure-analysis 示例
`docs/`	Normative policy 与开发文档
`reports/`	冻结的 scientific/objectivity audit
`runs/`, `out/`	开发 log 与 summary
`paper_drafts/`	Manuscript framing、evidence ledger 与本报告

附录 B：指标解释检查表

指标	有效解释	无效解释
`held_out_prediction_score`	固定 held-out condition–readout pairs 上的连续预测准确度	声明评测域以外的代数等价
`predictive_model_pass`	Predictor 通过 case-specific hidden numerical test	Explanation 在科学上完整
`protocol_completion`	存在可严格 decode 的最终主张	科学正确性
`experiment_discriminativeness_mean`	Player forecast 在所选合法实验上有差异	Expected information gain 或 optimal design
`evidence_aligned_belief_update_rate`	报告 pairwise support 朝 lower-error forecast 移动	Bayesian posterior validity 或 calibration
LLM evaluator axes	对可观察 transcript 的探索性定性评分	Ground truth 或 executable scoring 的替代物

参考文献

引用由 references.bib 解析。

Bertolazzi, Leonardo, Katya Tentori, and Raffaella Bernardi. 2026. "FALSIFYBENCH: Evaluating Inductive Reasoning in LLMs with Rule Discovery Games." *arXiv Preprint arXiv:2606.04751*. https://arxiv.org/abs/2606.04751.

Brunton, Steven L., Joshua L. Proctor, and J. Nathan Kutz. 2016. "Discovering Governing Equations from Data by Sparse Identification of Nonlinear Dynamical Systems." *Proceedings of the National Academy of Sciences* 113 (15): 3932–37. https://doi.org/10.1073/pnas.1517384113.

Chen, Tingting, Beibei Lin, Srinivas Anumasa, et al. 2025. "Auto-Discovery-Bench: Diagnosing Structured State Tracking in Oracle-Guided Discovery." *arXiv Preprint arXiv:2502.15224*. https://arxiv.org/abs/2502.15224.

Chen, Yimeng, Piotr Piękos, Mateusz Ostaszewski, Firas Laakom, and Jürgen Schmidhuber. 2025. "PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors." *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*. https://arxiv.org/abs/2507.15550.

Chen, Ziru, Shijie Chen, Yuting Ning, et al. 2025. "ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery." *International Conference on Learning Representations*. https://arxiv.org/abs/2410.05080.

Jansen, Peter, Marc-Alexandre Côté, Tushar Khot, et al. 2024. "DISCOVERYWORLD: A Virtual Environment for Developing and Evaluating Automated Scientific Discovery Agents." *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*. https://arxiv.org/abs/2406.06769.

Koblischke, Nolan, Hyunseok Jang, Kristen Menou, and Mohamad Ali-Dib. 2025. "Gravity-Bench-v1: A Benchmark on Gravitational Physics Discovery for Agents." *Proceedings of the 42nd International Conference on Machine Learning*. https://arxiv.org/abs/2501.18411.

Kon, Patrick Tser Jern, Jiachen Liu, Xinyi Zhu, et al. 2026. "EXP-Bench: Can AI Conduct AI Research Experiments?" *International Conference on Learning Representations*. https://arxiv.org/abs/2505.24785.

Schmidt, Michael, and Hod Lipson. 2009. "Distilling Free-Form Natural Laws from Experimental Data." *Science* 324 (5923): 81–85. https://doi.org/10.1126/science.1165893.

Starace, Giulio, Oliver Jaffe, Dane Sherburn, et al. 2025. "PaperBench: Evaluating AI's Ability to Replicate AI Research." *arXiv Preprint arXiv:2504.01848*. https://arxiv.org/abs/2504.01848.

Udrescu, Silviu-Marian, and Max Tegmark. 2020. "AI Feynman: A Physics-Inspired Method for Symbolic Regression." *Science Advances* 6 (16): eaay2631. https://doi.org/10.1126/sciadv.aay2631.

Wang, Ruoyao, Peter Jansen, Marc-Alexandre Côté, and Prithviraj Ammanabrolu. 2022. "ScienceWorld: Is Your Agent Smarter Than a 5th Grader?" *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, 11279–98. https://doi.org/10.18653/v1/2022.emnlp-main.775.

Wang, Zhen, Fan Bai, Zhongyan Luo, et al. 2026. "FIRE-Bench: Evaluating Agents on the Rediscovery of Scientific Insights." *arXiv Preprint arXiv:2602.02905*. https://arxiv.org/abs/2602.02905.

Wiemann, Matt L., Lindsay M. Smith, Peter Melchior, et al. 2026. "DiscoverPhysics: Benchmarking LLMs for Out-of-the-Box Scientific Thinking." *arXiv Preprint arXiv:2605.26087*. https://arxiv.org/abs/2605.26087.

Zheng, Lianmin, Wei-Lin Chiang, Ying Sheng, et al. 2023. "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena." *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*. https://arxiv.org/abs/2306.05685.

Zheng, Tianshi, Kelvin Kiu-Wai Tam, Newt Hue-Nam K. Nguyen, et al. 2026. "NewtonBench: Benchmarking Generalizable Scientific Law Discovery in LLM Agents." *International Conference on Learning Representations*. https://openreview.net/forum?id=Gk6umqW74m.